

# **Statistik – Methoden zum Vergleich von zwei Gruppen**


Unterstützende Signifikanztests

# Verteilungstests

- Für verschiedene statistische Testverfahren (z.B. z-Test, t-Test) ist es notwendig, dass die zu untersuchenden Daten einer Normalverteilung folgen
- Gilt besonders für kleine Stichproben ( $n < 30$ )
- Wir benötigen Werkzeuge, die die Normalverteilungsannahme überprüfen können
- Des weiteren können einige der aufgeführten Testverfahren auch andere Verteilungsformen identifizieren, zum Teil können auch Stichproben gegeneinander geprüft werden (nicht Bestandteil des RCommander)

# Verteilungstests

- Ein grafischer Vergleich der Daten mit einer Normalverteilung liefert Hinweise, wie nah man der geforderte Normalverteilung ist, macht aber keine statistisch signifikante Aussage
- Trotzdem sollte immer eine grafische Überprüfung erfolgen!!!



# Verteilungstests

- Einige im RCommander genutzte Verteilungstests (nur Normalverteilung)

Test	
Shapiro-Wilk (SW)	Standardtest
$\chi^2$ -Test (Chi)	Datenklassifizierung erforderlich
Anderson-Darling (AD)	Six Sigma / englisch sprachiger Raum
Kolmogorov-Smirnov (KS)	Klassiker
Cramer von Mises (CM)	Starke Abhängigkeit von der Stichprobengröße
Shapiro-Francia (SF)	SW-Abwandlung für platokurtische Verteilungen
(Epps-Pulley)	Tolerant gegen Abweichungen
(Jarque-Bera)	Tolerant gegen Abweichungen

# Verteilungstests

- Es gibt nicht den einen Test auf Normalverteilung, alle aufgeführten Tests haben Schwächen und Stärken, sie führen auch zum Teil zu divergierenden Aussagen
- Je nach Stichprobengröße sind einzelne Testverfahren besser oder schlechter geeignet
- Kleine Stichproben
  - + Shapiro-Wilk, Anderson-Darling, Kolmogorow-Smirnov
- Große Stichproben
  - + Shapiro-Wilk,  $\chi^2$ -Test

# Verteilungstests

Für alle aufgeführten Testverfahren gelten die gleichen Hypothesen

- Wichtig für die Auswertung des p-Wertes !!!

$H_0$  Die Daten folgen der zugrunde gelegten Verteilung (z.B. der Normalverteilung)

$H_1$  Die Daten folgen **nicht** der zugrunde gelegten Verteilung (z.B. der Normalverteilung)

- Das Signifikanzniveau wird im allgemeinen zu  $\alpha = 5\%$  gesetzt

# Beispiel: Anderson-Darling-Test

- Der Anderson-Darling-Test kann für verschiedene Verteilungsformen eingesetzt werden
- Verwendung für die Überprüfung der Normalverteilungsannahme
- Hohe Trennschärfe

# Beispiel: Anderson-Darling-Test

## Das Testverfahren

- Zu untersuchenden Daten werden der Größe nach sortiert
- Anschließend erfolgt eine Transformation der sortierten Daten in eine Gleichverteilung
- Anschließend wird die Übereinstimmung mit einer Gleichverteilungsfunktion überprüft
- Das Ergebnis der Prüfung kann in einen p-Wert überführt werden



# Beispiel: Anderson-Darling-Test

Die Testgröße

$$AD^2 = -n - S \quad (\text{AD steht für Anderson Darling})$$

$$S = \sum_{k=1}^n \frac{2k-1}{n} [\ln F(Y_k) + \ln(1 - F(Y_{n+1-k}))]$$

n: Stichprobengröße

F: Die Funktion der F-Verteilung

# Beispiel: Anderson-Darling-Test

Der p-Wert

- $$z = AD^2 \left( 1 + \frac{0,75}{n} + \frac{2,25}{n^2} \right)$$

z	p-Wert
$z \leq 0,2$	$1 - \exp(-13,436 + 101,14 * z - 223,73 * z^2)$
$0,2 < z \leq 0,34$	$1 - \exp(-8,318 + 42,796 * z - 59,938 * z^2)$
$0,34 < z \leq 0,6$	$\exp(0,9177 - 4,279 * z - 1,38 * z^2)$
$0,6 < z$	$\exp(1,2937 - 5,709 * z + 0,0186 * z^2)$

# Beispiel: Anderson-Darling-Test

## Voraussetzungen für den Test

- Metrisch skalierte Daten
- Daten lassen sich in eine Gleichverteilung transformieren
- Stichprobengröße  $n \geq 8$

# Verteilungstests

## Beispiel

Datei *Übung\_Deskriptiv.xlsx*, Daten NV und NNV

Führen Sie die verschiedenen Testverfahren durch und vergleichen Sie die Werte.

# Verteilungstests

## Beispiel

Datei *Übung\_Deskriptiv.xlsx*, Daten NV und NNV

Test	p-Wert (NV)	p-Wert (NNV)
SW	0,3076	3,333e-10
Chi	0,8508	8,707e-11
AD	0,1914	1,015e-14
KS	0,1367	1,556e-11
CM	0,1525	9,585e-10
SF	0,3076	0,000000005747

# Ryan-Joiner-Test

- Korrelationsverfahren zur Überprüfung der Normalverteilung
- Der Ryan-Joiner-Test bestimmt einen Koeffizienten für die Korrelation der Daten und den normalverteilten Werten der Daten
- Liegt dieser Koeffizient nahe 1, so liegen die Daten am Wahrscheinlichkeitsnetz der Normalverteilung

# Ryan-Joiner-Test

## Teststatistik

$$R_p = \frac{\sum (Y_i - \bar{Y}) b_i}{\sqrt{s^2 (n - 1) \sum b_i^2}}$$

mit

$Y_i$  geordnete Beobachtungen

$b_i$  normalverteilte Werte der geordneten Beobachtungen

$s^2$  Stichprobenvarianz


# QQ - Diagramm

- Quantil-Quantil-Diagramm
- Grafische Überprüfung von Daten auf Normalverteilung (auch für andere Verteilungsformen)
- Vergleichbar mit dem Wahrscheinlichkeitsnetz
- Es ersetzt nicht den Verteilungstest, aber grafische Werkzeuge sollten immer parallel eingesetzt werden!




# QQ - Diagramm

- Die Gerade stellt hier den Verlauf der Normalverteilung dar
- Sind die Daten normalverteilt, folgen die Datenpunkte möglichst genau der Geraden



# QQ - Diagramm

- Überlagerung von Verteilungen



# Test auf Varianzhomogenität

- Signifikanztests zur Prüfung der Gleichheit von Varianzen
- Die vorgestellten Tests können auf zwei (F-Test) oder mehr Gruppen (Bartlett/Levene) gleichzeitig angewandt werden
- Für alle Tests gelten die Voraussetzungen:
  - Unabhängige Beobachtungen
  - Metrisches Skalenniveau
  - Normalverteilung (nur Bartlett und F-Test), der Levene-Test ist auch für Nichtnormalverteilungen geeignet

# Test auf Varianzhomogenität

- Verschiedene Tests und ihr Einsatzgebiet

Test	Normalverteilung	Stichproben	Ein/zweiseitig?
Levene-Test	Nein	$\geq 2$	zweiseitig
Bartlett-Test	Ja	$\geq 2$	zweiseitig
F-Test	Ja	$= 2$	ein-/zweiseitig

# Test auf Varianzhomogenität

## Hypothesen für Levene und Bartlett

### Nullhypothese

$$H_0: \sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2$$

### Alternativhypothese

$$H_1: \sigma_i^2 \neq \sigma_j^2 \text{ für mindestens ein Gruppenpaar } i, j \text{ mit } i \neq j$$

Der F-Test kann ein- und zweiseitig genutzt werden, entsprechend müssen hier die Alternativhypothesen eingestellt werden

# Test auf Varianzhomogenität

## Anmerkungen

- Bartlett-Test: Trennschärfer als Levene, setzt aber Normalverteilung voraus und sollte annähernd gleiche Stichprobengrößen aufweisen
- Levene-Test: Robust bei nicht-normalverteilten Daten und bei unterschiedlich großen Stichproben
- F-Test: Höchste Trennschärfe, aber sehr empfindlich bei Nicht-Normalität

# Test auf Varianzhomogenität

## Beispiel

*Beispiel\_Var.xlsx*

Untersuchung auf ungleiche Streuung / Varianz


$$H_0 \quad \sigma_1^2 = \sigma_2^2$$

$$H_1 \quad \sigma_1^2 \neq \sigma_2^2$$

# Test auf Varianzhomogenität

## Beispiel

- **Unterschiedliche Streuungen**





# Test auf Varianzhomogenität

## Beispiel

```
Levene's Test for Homogeneity of Variance (center = "median")
```

```
      Df F value    Pr(>F)
group  1  67.007 1.017e-12 ***
      98
```

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Der p-Wert wird in der R-Ausgabe als Pr bezeichnet

# Test auf Varianzhomogenität

## Beispiel

Bartlett test of homogeneity of variances

data: Werte by Index

Bartlett's K-squared = 79.646, df = 1, p-value < 2.2e-16

# Test auf Varianzhomogenität

## Beispiel

F test to compare two variances

data: Werte by Index

F = 0.053739, num df = 49, denom df = 49, p-value < 2.2e-16

alternative hypothesis: true ratio of variances is not equal to 1

95 percent confidence interval:

0.03049562 0.09469829

sample estimates:

ratio of variances

0.05373903

# Signifikanztest für Korrelationen

- Korrelation auf Signifikanz prüfen
- Gibt es in zwischen Gruppen eine Korrelation, kann geprüft werden, ob diese auch statistisch signifikant ist
- Ab welchem Betrag ist ein Korrelationskoeffizient statistisch signifikant?

# Signifikanztest für Korrelationen

- Testverfahren: t-Tests, eine Stichprobe
- Weicht der Korrelationskoeffizient signifikant von 0 ab
- Prüfung auf lineare Unabhängigkeit

## Nullhypothese

$H_0$        $r = 0$ , es besteht keinen Zusammenhang zwischen den Gruppen

## Alternativhypothesen

$H_1$        $r \neq 0$ , es besteht ein Zusammenhang zwischen den Gruppen

# Signifikanztest für Korrelationen

## Teststatistik

$$t = \frac{r * \sqrt{n - 2}}{\sqrt{1 - r^2}}$$





- Diesen Wert kann man mit einem kritischen Wert  $t_{krit}$  vergleichen, der z.B. einer t-Tabelle entnommen werden kann
- Anzahl der Freiheitsgrade  $df = n - 2$

# Ausreißer

- Bei der ersten Analyse unserer Daten fallen immer wieder Werte auf, die scheinbar nicht zum Datensatz passen
- Wir neigen dazu, diese Werte per se als Ausreißer zu identifizieren
- Sie verhindern teilweise, dass wir parametrische Verfahren zur Datenanalyse nutzen, wir müssen auf nicht-parametrische Verfahren ausweichen

# Ausreißer

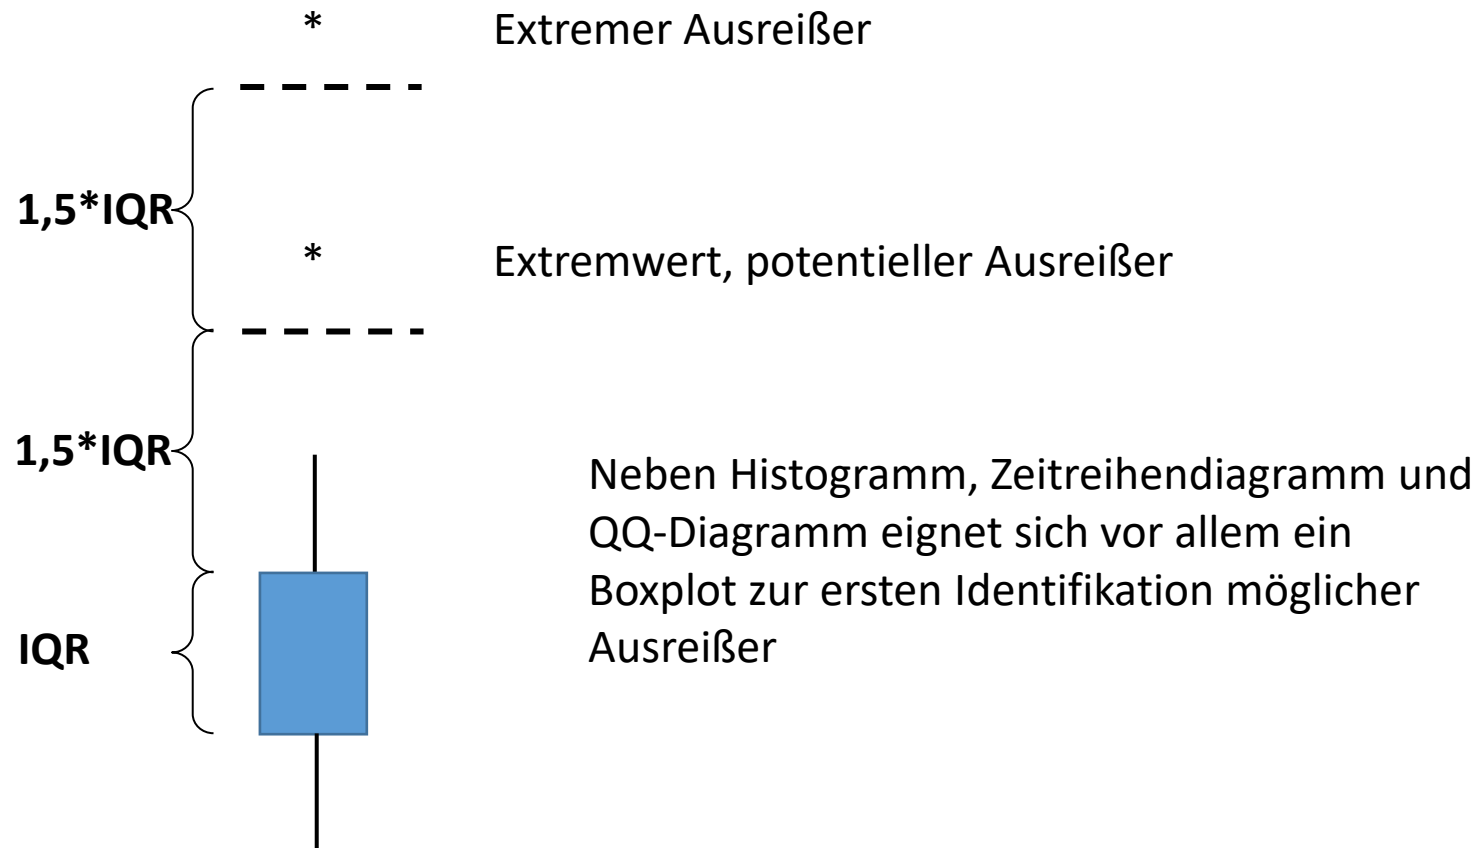
- Datenpunkt 9 ist in mehreren Grafiken auffällig
- (Beispiel\_Ausreisser.xlsx / Daten)





# Ausreißer

- Definition von Ausreißern im Boxplot



# Ausreißer

- Führt man einen Test auf Normalverteilung durch, sieht man möglicherweise eine Nichtnormalverteilung

```
Shapiro-Wilk normality test
```

```
data: Daten  
W = 0.95365, p-value = 0.04826
```

- Ohne auffällige Werte können wir unter Umständen von einer Normalverteilung ausgehen

```
Shapiro-Wilk normality test
```

```
data: DatenoA  
W = 0.98526, p-value = 0.7924
```

# Ausreißer

- Andererseits wissen wir, dass Normalverteilungen durchaus eine größere Bandbreite haben können
- Wir benötigen also Verfahren, die Werte hinsichtlich ihrer ungewöhnlichen Lage überprüfen
- Ausreißer-Test
  - Grubb's Test
  - David-Hartley-Pearson-Test
  - Dixon's r-Statistiken
- Voraussetzung für all diese Verfahren:  
Normalverteilte Daten (ohne Ausreißer)

# Ausreißer

- Belegt ein Ausreißer-Test das Vorliegen eines Ausreißers, stellt sich die Frage: Wie mit diesem Wert umgehen?
- Mögliches Vorgehen:
  - Identifizierte Ausreißer auf Mess-, Rechen-, Schreib- oder Datenerfassungsfehler (systematischer Fehler) überprüfen und ggf. korrigieren/entfernen
  - Entscheiden, ob der Wert überhaupt zur Stichprobe gehört
  - Gegebenenfalls wird der Wert aus der Stichprobe entfernt

# Ausreißer: Grubb's Test

- Testverfahren zur Überprüfung des Minimal- und/oder Maximalwertes des Datensatzes

Voraussetzungen:

- Die Stichprobe (ohne Ausreißer) ist normalverteilt
- Es befinden sich maximal zwei Ausreißer in der Stichprobe (ansonsten muss der Test mehrfach wiederholt werden, wobei identifizierte Ausreißer entfernt werden)
- Grubbs' Ausreißertest kann ein- oder zweiseitig angesetzt werden

# Ausreißer: Grubb's Test

- Hypothesen

$H_0$       Der Datensatz enthält keine Ausreißer

$H_1$       Es gibt mindestens einen Ausreißer im Datensatz

- Teststatistik

$$G = \frac{\max |x_i - \bar{x}|}{s}$$

mit       $\bar{x}$ : Stichprobenmittelwert

$s$ : Standardabweichung der Stichprobe

# Ausreißer: Grubb's Test

- Kritischer Wert  $G_{krit}$ 
  - Beispiel: Zweiseitiger Test

$$G_{krit} = \frac{(n-1)}{\sqrt{n}} \sqrt{\frac{\left(t_{\frac{\alpha}{2n}, n-2}\right)^2}{n-2 + \left(t_{\frac{\alpha}{2n}, n-2}\right)^2}}$$

$t_{\frac{\alpha}{2n}, n-2}$  erhält man aus einer t-Verteilung mit  $df = n - 2$   
Freiheitsgraden und einem Signifikanzniveau von  $\alpha/2n$

Für  $G > G_{krit}$  wird die Nullhypothese verworfen

# Ausreißer: Grubb's Test

- Kritischer Wert  $G_{krit}$ 
  - Für den einseitigen Test wird das Signifikanzniveau zu  $\alpha/n$  gewählt



# Ausreißer: Grubb's Test

## Berechnung in R

- Im RCommander sind keine Ausreißer-Tests hinterlegt
- Installation des Package „Outliers“
- `install.packages(„outliers“)`
- `library(outliers)`

# Ausreißer: Grubb's Test

## Berechnung in R

```
grubbs.test(x, type = 10, opposite = FALSE, two.sided = FALSE)
```

mit

x

Datenvektor

type

Testvariante (10 – ein Ausreißer; 11 – zwei Ausreißer auf gegenüberliegenden Seiten des Datensatzes; 20 – zwei Ausreißer auf einer Seite des Datensatzes)

opposite

FALSE – Überprüfung des Datenpunktes mit dem größten Mittelwertabstand

TRUE – Überprüfung des gegenüberliegenden Punktes

two.sided

FALSE – einseitiger Test

TRUE – zweiseitiger Test

# Ausreißer: Grubb's Test

Berechnung in R

Vorsicht, nur folgende Kombinationen machen Sinn

`type = 10 und two.sided = FALSE`

`type = 11 und two.sided = TRUE`

andernfalls wird der  $\alpha$ -Wert falsch interpretiert

# Ausreißer: Grubb's Test


- Beispiel\_Ausreisser.xlsx (Daten)
- Datenpunkt 9 ist ein potentieller Ausreißer

Shapiro-Wilk normality test

data: Daten

W = 0.95365, p-value = 0.04826

- Der Originaldatensatz ist nicht normalverteilt




# Ausreißer: Grubb's Test

- Beispiel\_Ausreisser.xlsx (DatenoA)
- Überprüfung ohne Punkte 9

Shapiro-Wilk normality test

```
data:  DatenoA  
W = 0.98526, p-value = 0.7924
```

- Der veränderte Datensatz ist normalverteilt



# Ausreißer: Grubb's Test

- Beispiel\_Ausreisser.xlsx (Daten)
- Hier: Test auf einen Ausreißer

```
> with(Dataset, grubbs.test(Daten, type=10, opposite=FALSE, two.sided=FALSE))
```

```
Grubbs test for one outlier
```

```
data: Daten
```

```
G = 3.46375, U = 0.75015, p-value = 0.005479
```

```
alternative hypothesis: lowest value 6.1004376 is an outlier
```

**p < 0,05:            Alternativhypothese – Datenpunkt 9 ist ein Ausreißer**

# Ausreißer: Grubb's Test

- Beispiel\_Ausreisser.xlsx (Daten)
- Hier: Test auf zwei Ausreißer (gegenüberliegende Seiten)

```
> with(Dataset, grubbs.test(Daten, type=11, opposite=FALSE, two.sided=TRUE))
```

```
Grubbs test for two opposite outliers
```

```
data: Daten
```

```
G = 5.29914, U = 0.68528, p-value = 0.1517
```

```
alternative hypothesis: 6.1004376 and 11.833236 are outliers
```

$p > 0,05$ : Nullhypothese – Datenpunkte 9 und 50 sind keine Ausreißer

# Ausreißer: Grubb's Test

- Beispiel\_Ausreisser.xlsx (Daten2A)
- Hier: Test auf zwei Ausreißer (gegenüberliegende Seiten)

```
> with(Dataset, grubbs.test(Daten2A, type=11, opposite=FALSE, two.sided=TRUE))
```

```
Grubbs test for two opposite outliers
```

```
data: Daten2A
```

```
G = 5.97107, U = 0.63081, p-value = 0.00871
```

```
alternative hypothesis: 6.1004376 and 12.833236 are outliers
```

$p < 0,05$ :      Alternativhypothese – Datenpunkte 9 und 50 sind  
Ausreißer