

Statistik – Methoden zum Vergleich von zwei Gruppen

Trennschärfe und Poweranalyse

Trennschärfe / Power

- Bisheriger Fokus bei der Auswertung von Hypothesentests:
 - α -Fehler, Fehler 1. Art
 - Fehler: Wechsel zur Alternativhypothese, obwohl die Nullhypothese richtig ist
 - Wechsel zu Alternativhypothese erst, wenn die Wahrscheinlichkeit $(1-\alpha)$ des Fehlers klein genug ist
- Spezifität eines Hypothesentests

Trennschärfe / Power

		Realität	
		H_0 ist wahr	H_1 ist wahr
Testergebnis	Verbleib bei H_0	Korrekte Entscheidung $(1 - \alpha)$ (Spezifität)	Fehler 2. Art (β)
	Wechsel zu H_1	Fehler 1. Art (α)	Korrekte Entscheidung $(1 - \beta)$ (Trennschärfe)

Trennschärfe / Power


- Perspektivwechsel
- β -Fehler, Fehler 2.Art
- Fehler: Verbleib in der Nullhypothese, obwohl die Alternativhypothese richtig ist
- Die Wahrscheinlichkeit $(1-\beta)$ mit dem Wechsel zur Alternativhypothese die korrekte Entscheidung zu treffen ist ein Gütekriterium für Hypothesentests
- Trennschärfe, Power eines Hypothesentests

Trennschärfe / Power

- Trennschärfe
- Unterschiede erkennen, wenn sie tatsächlich vorhanden sind
- Mit welcher Wahrscheinlichkeit wird die Nullhypothese H_0 korrekt abgelehnt
- Mit welcher Wahrscheinlichkeit wird die Alternativhypothese H_1 korrekt gewählt

Trennschärfe / Power

Zusammenhang Trennschärfe / Irrtumswahrscheinlichkeit



Trennschärfe / Power

Zusammenhang Trennschärfe / Irrtumswahrscheinlichkeit

- Wenn $(1-\beta)$ klein ist, d.h. die Trennschärfe des Tests niedrig
 - Verbleibt man bei der Nullhypothese, ist diese nur eingeschränkter Wahrscheinlichkeit auch wahr
- Bei einem vorgegebenen Testszenario wirkt die Veränderung von α auch auf $(1-\beta)$
 - Absenken des α führt zu sinkender Teststärke $(1-\beta)$
 - Kompromiss erforderlich

Trennschärfe / Power


Trennschärfe-Analyse / Power-Analyse

- Bestimmung der erforderlichen Stichprobengröße, bei der mit der Wahrscheinlichkeit $(1-\beta)$ ein Effekt einer bestimmten Größe erkannt werden kann

Trennschärfe / Power

Einflussfaktoren der Trennschärfe

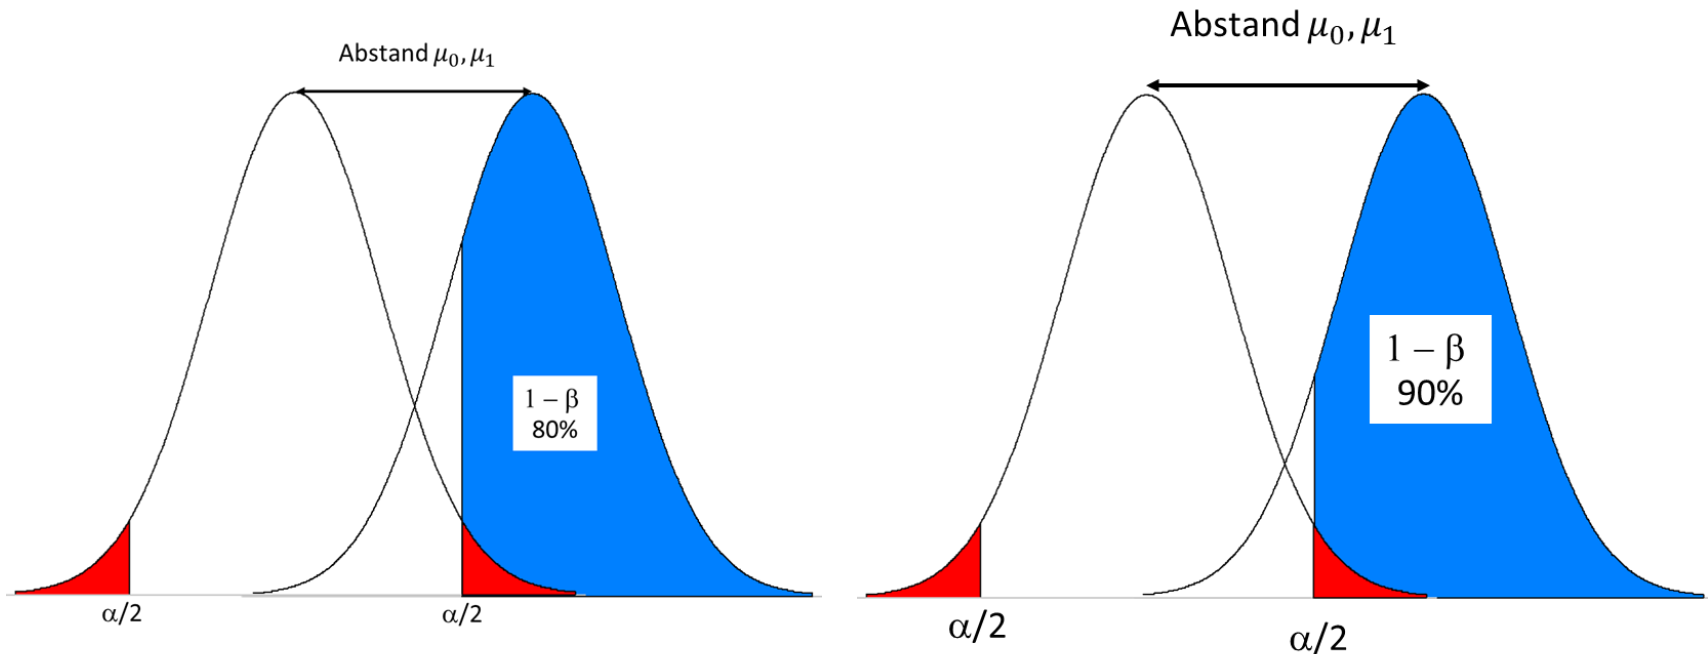
- Die Trennschärfe eines Tests kann auf verschiedene Arten verbessert werden
- Erkennen Sie Möglichkeiten?



Trennschärfe / Power

Einflussfaktor Abstand μ_0, μ_1


- Abstand Vergrößern $1 - \beta$ wächst



Trennschärfe / Power

Einflussfaktor Varianz / Streuung


- Streuung verringern $1-\beta$ wächst



Trennschärfe / Power

Einflussfaktor Irrtumswahrscheinlichkeit α

- Irrtumswahrscheinlichkeit α erhöhen $1 - \beta$ wächst



Trennschärfe / Power

Einflussfaktor Stichprobenumfang n


$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

- Streuung sinkt $1-\beta$ wächst

Trennschärfe / Power

Einflussfaktor ein- / zweiseitiger Test

- Test einseitig (α wächst einseitig) 1- β wächst



Trennschärfe / Power

Einflussfaktor Testauswahl

- Für einzelne Fragestellungen gibt es unterschiedlich starke Tests (z.B. Prüfung auf Normalverteilung)
- Auswahl starker Tests
- Parametrische Tests sind i.a. stärker als nicht-parametrische Tests
- Wo möglich parametrische Tests wählen

Trennschärfe / Power

Grundlegendes Problem bei der Berechnung von Teststärke bzw. Stichprobengröße:

- Bestimmung der Effektstärke
- Für die t-Testfamilie kennen wir bereits den Cohen's D
- Für alle weitergehenden Berechnungen benötigen wir Definitionen der entsprechenden Effektstärken

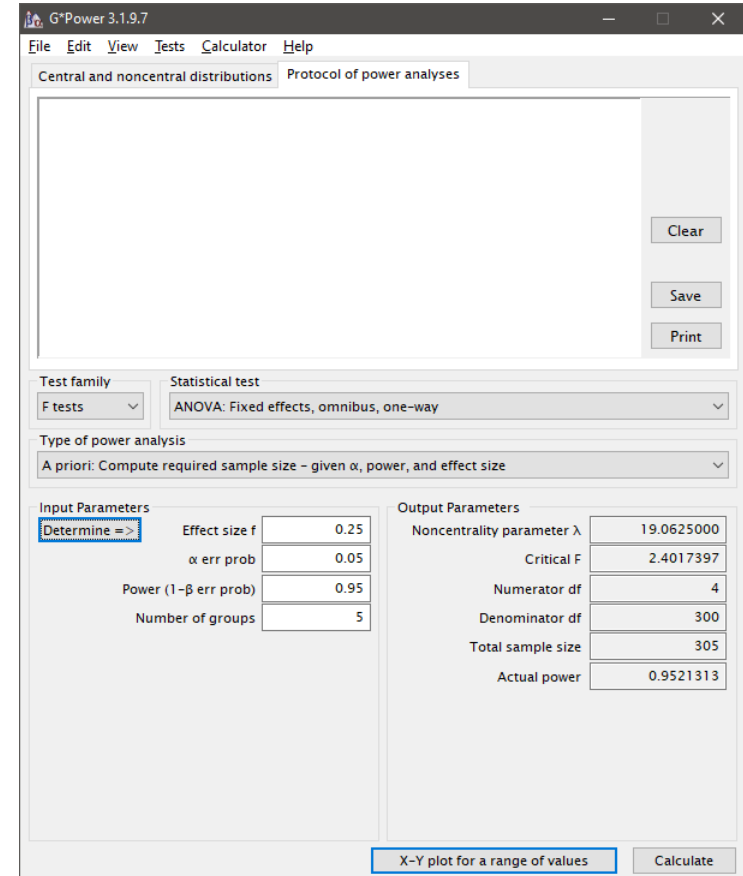

Trennschärfe / Power

Beispiel Einfaktorielle ANOVA

- Grundlage der Berechnung von Trennschärfe bzw. Stichprobenumfang ist eine F-Verteilung, meistens um einen Nichtzentralitätsparameter ergänzt
- Die Berechnung wird dabei iterativ ausgeführt
- Auf die entsprechenden Formulierungen wird an dieser Stelle verzichtet
- Berechnung über RStudio und gpower möglich, keine Berechnung über den RCommander

Trennschärfe / Power

- Eingabefenster gPower für die einfaktorielle Varianzanalyse (Beispiel)
- Type of power analysis




Trennschärfe / Power

- Ausgabe
- Sample Size
- Power


The screenshot shows the G*Power 3.1.9.7 software interface. The 'Central and noncentral distributions' tab is selected. The 'Test family' is set to 'F tests' and the 'Statistical test' is 'ANOVA: Fixed effects, omnibus, one-way'. The 'Type of power analysis' is 'A priori: Compute required sample size - given α , power, and effect size'. The 'Input Parameters' section includes a 'Determine =>' button and fields for 'Effect size f' (0.25), ' α err prob' (0.05), 'Power (1- β err prob)' (0.95), and 'Number of groups' (5). The 'Output Parameters' section displays calculated values: 'Noncentrality parameter λ ' (19.0625000), 'Critical F' (2.4017397), 'Numerator df' (4), 'Denominator df' (300), 'Total sample size' (305), and 'Actual power' (0.9521313). A 'Calculate' button is at the bottom right, and an 'X-Y plot for a range of values' button is at the bottom left of the output section.

Input Parameters		Output Parameters	
Determine =>	Effect size f	Noncentrality parameter λ	19.0625000
	α err prob	Critical F	2.4017397
	Power (1- β err prob)	Numerator df	4
	Number of groups	Denominator df	300
		Total sample size	305
		Actual power	0.9521313

Trennschärfe / Power



- Verschiedene Möglichkeiten die Operationscharakteristik (OC) grafisch darzustellen



Trennschärfe / Power

- Zur Berechnung von Stichprobengrößen kann man neben gpower auch ein Paket in r nutzen
- Die Berechnung erfolgt über RStudio, nicht über den RCommander

```
> install.packages(„pwr“)  
> library(pwr)
```

bzw.

```
> install.packages(„WebPower“)  
> library(WebPower)
```

- Die enthaltenen Analysen kann man sich in der r-Hilfe anschauen

Trennschärfe / Power

Für Aussagen über Stichprobengröße benötigen wir folgende Informationen:

- Effektgröße
 - Wie groß ist der Effekt, den man unterscheiden möchte
 - Je größer der Effekt ist, um so leichter ist er festzustellen bzw. um so kleiner kann die Stichprobe sein

Trennschärfe / Power

- Power bzw. Teststärke ($1-\beta$)
 - Wahrscheinlichkeit die Nullhypothese korrekt abzulehnen bzw. die Alternativhypothese zu wählen, wenn sie richtig ist
 - Je größer ($1-\beta$), um so leichter kann man einen Effekt identifizieren, aber um so größer müssen Stichproben sein

Trennschärfe / Power

- Signifikanzniveau α
 - Wahrscheinlichkeit, die Nullhypothese abzulehnen, obwohl sie richtig ist
 - Je niedriger das Signifikanzniveau gewählt wird, um so besser lehnt man eine Alternativhypothese ab, wenn sie falsch ist, um so größere Stichproben benötigt man aber auch

Trennschärfe / Power

- Wir haben bereits im Zusammenhang mit der t-Testfamilie die Effektgröße Cohen's D kennengelernt
- Für andere Testverfahren benötigen wir aber andere Effektdefinitionen
- Diese folgen nun mit einer Darstellung ihrer Nutzung in r und gpower

Effektdefinition für verschiedene Tests

t-Test, 1 Stichprobe

- Effekt: Cohen's D

- $$D = \frac{\bar{x} - \mu_0}{s}$$

pwr.t.test(n = , d = , sig.level = , power = , type = "one.sample", alternative=)

- **n** Stichprobengröße
- **d** Effektgröße
- **sig.level** α
- **power** $1 - \beta$
- **type** Test
- **alternative** "less", "two.sided", "greater"

Effektdefinition für verschiedene Tests

t-Test, 1 Stichprobe

```
> pwr.t.test(d=0.50,n=50, sig.level =0.05, type="one.sample", alternative="two.sided")
```

One-sample t test power calculation

```
      n = 50
      d = 0.5
sig.level = 0.05
  power = 0.9338976
alternative = two.sided
```

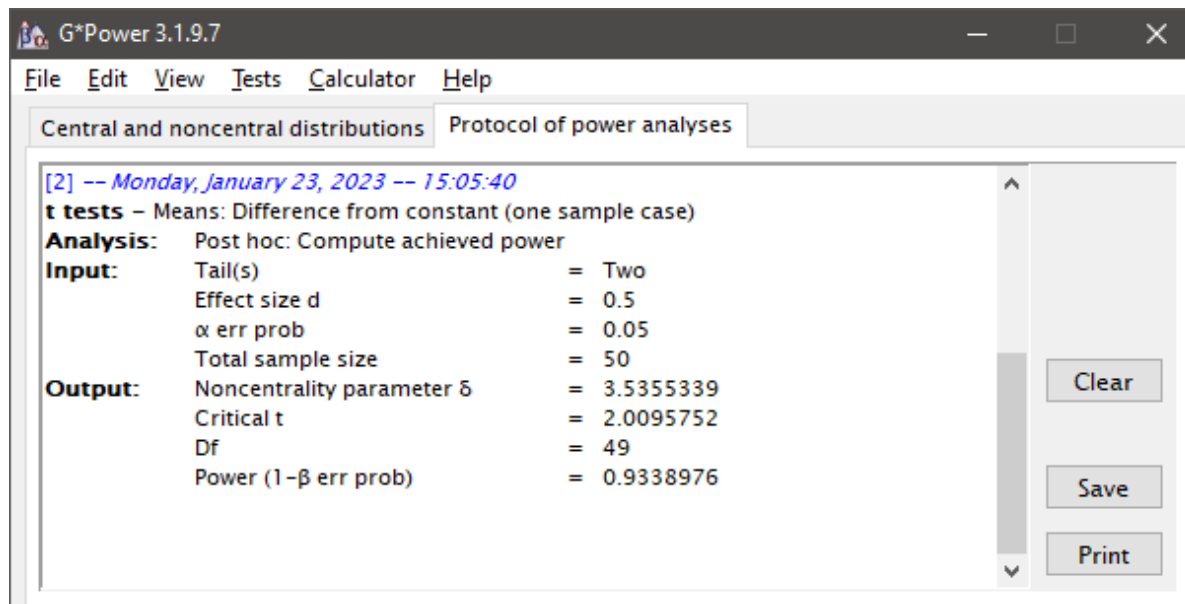
```
> pwr.t.test(d=0.50, sig.level =0.05,power=0.9, type="one.sample", alternative="two.sided")
```

One-sample t test power calculation

```
      n = 43.99548
      d = 0.5
sig.level = 0.05
  power = 0.9
alternative = two.sided
```

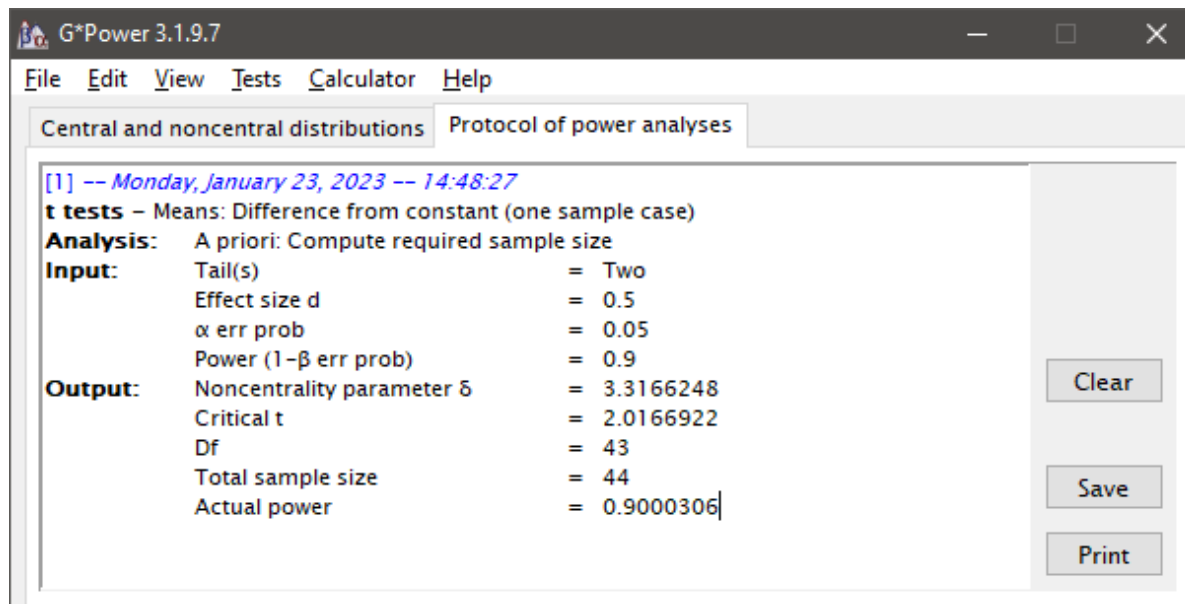
Effektdefinition für verschiedene Tests

t-Test, 1 Stichprobe



Effektdefinition für verschiedene Tests

t-Test, 1 Stichprobe



Effektdefinition für verschiedene Tests

t-Test, 2 unabhängige Stichproben

- Effekt: Cohen's D

- $$D = \frac{\bar{x}_2 - \bar{x}_1}{s_{pooled}}$$

pwr.t.test(n = , d = , sig.level= , power = , type = "two.sample", alternative=)

- **n** Stichprobengröße
- **d** Effektgröße
- **sig.level** α
- **power** $1 - \beta$
- **type** Test
- **alternative** "less", "two.sided", "greater"

Effektdefinition für verschiedene Tests

t-Test, gepaarte Stichproben

- Effekt: Cohen's D

- $$D = \frac{\bar{x}_2 - \bar{x}_1}{s_{pooled}}$$

pwr.t.test(n = , d = , sig.level= , power = , type = "paired", alternative=)

- **n** Stichprobengröße
- **d** Effektgröße
- **sig.level** α
- **power** $1 - \beta$
- **type** Test
- **alternative** "less", "two.sided", "greater"

Effektdefinition für verschiedene Tests

Einfaktorielle Varianzanalyse (ANOVA)

- Effekt: f

- $f = \sqrt{\frac{\eta^2}{1-\eta^2}}$ mit $\eta^2 = \frac{SS_{Zwischen}}{SS_{Gesamt}}$

pwr.anova.test(k = , n = , f = , sig.level = , power =)

- **k** Anzahl der Gruppen
- **n** Stichprobengröße (pro Gruppe)
- **f** Effektgröße
- **sig.level** α
- **power** $1 - \beta$

Effektdefinition für verschiedene Tests

Einfaktorielle Varianzanalyse (ANOVA)

```
> pwr.anova.test (k =6 , f =0.1 , sig.level =0.05 , power =0.80)
```

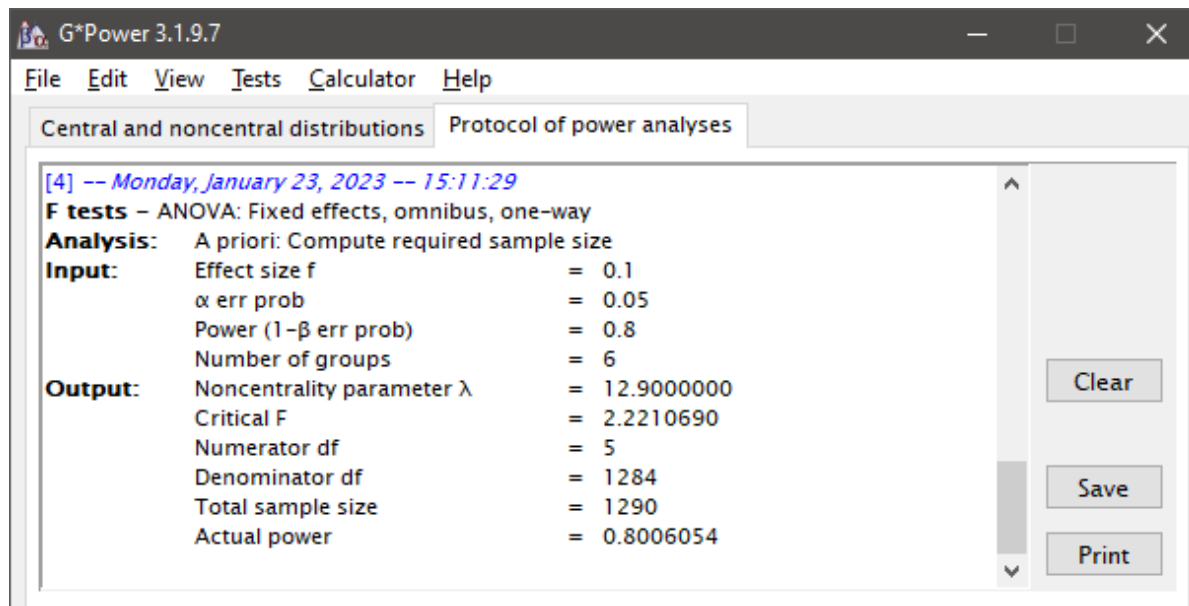
Balanced one-way analysis of variance power calculation

```
      k = 6  
      n = 214.7178  
      f = 0.1  
sig.level = 0.05  
power = 0.8
```

NOTE: n is number in each group

Effektdefinition für verschiedene Tests

Einfaktorielle Varianzanalyse (ANOVA)



Effektdefinition für verschiedene Tests

Single Proportion

- Effekt: h
- $h = 2 \arcsin \sqrt{p_1} - 2 \arcsin \sqrt{p_0}$

pwr.p.test(h = , n = , sig.level = , power = , alternative =)

- **h** Effektgröße
- **n** Anzahl der Beobachtungen
- **sig.level** α
- **power** $1 - \beta$
- **alternative** "less", "two.sided", "greater"

Effektdefinition für verschiedene Tests

Two Proportion

- Effekt: h
- $h = 2 \arcsin \sqrt{p_2} - 2 \arcsin \sqrt{p_1}$

pwr.2p.test(h = , n = , sig.level = , power = , alternative =)

- **h** Effektgröße
- **n** Anzahl der Beobachtungen (pro Stichprobe)
- **sig.level** α
- **power** $1 - \beta$
- **alternative** "less", "two.sided", "greater"

Effektdefinition für verschiedene Tests

χ^2 -Test (Anpassung)

- Effekt: w

- $$w = \sqrt{\frac{\chi^2}{n * df}}$$

`pwr.chisq.test(w = , N = , df = , sig.level=, power =)`

- **w** Effektgröße
- **N** Gesamtzahl der Beobachtungen
- **sig.level** α
- **power** $1 - \beta$

Effektdefinition für verschiedene Tests

χ^2 -Test (Anpassung)

```
> pwr.chisq.test (w=0.3, df=3, sig.level =0.05, power=0.8)
```

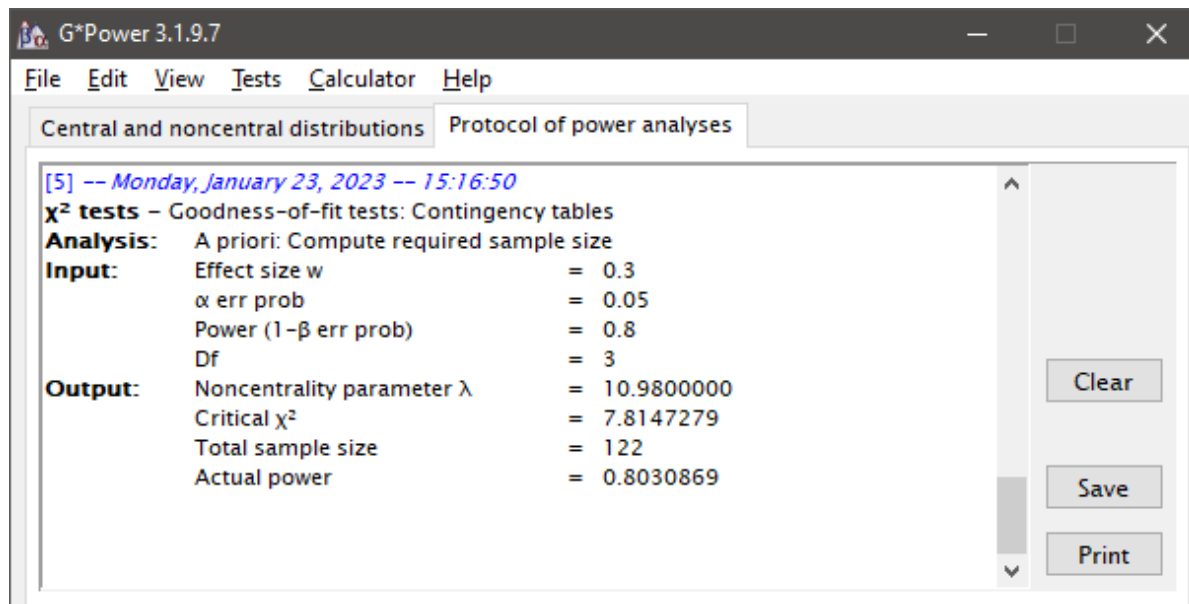
```
Chi squared power calculation
```

```
      w = 0.3  
      N = 121.1396  
      df = 3  
sig.level = 0.05  
power = 0.8
```

NOTE: N is the number of observations

Effektdefinition für verschiedene Tests

χ^2 -Test (Anpassung)



Effektdefinition für verschiedene Tests

Einfache lineare Regression

- Effekt: f^2
- $f^2 = r = \sqrt{R^2}$ (hier sollte der angepasste (adjusted) Wert genutzt werden)

`pwr.f2.test(u =, v =, f2 =, sig.level =, power =)`

- **u** Freiheitsgrade Zähler
- **v** Freiheitsgrade Nenner
- **f2** Effektstärke
- **sig.level** α
- **power** $1 - \beta$

Effektdefinition für verschiedene Tests

Einfache lineare Regression

```
> pwr.f2.test(u=1, f2=0.35, sig.level =0.05, power=0.9)
```

Multiple regression power calculation

$u = 1$

$v = 30.06969$

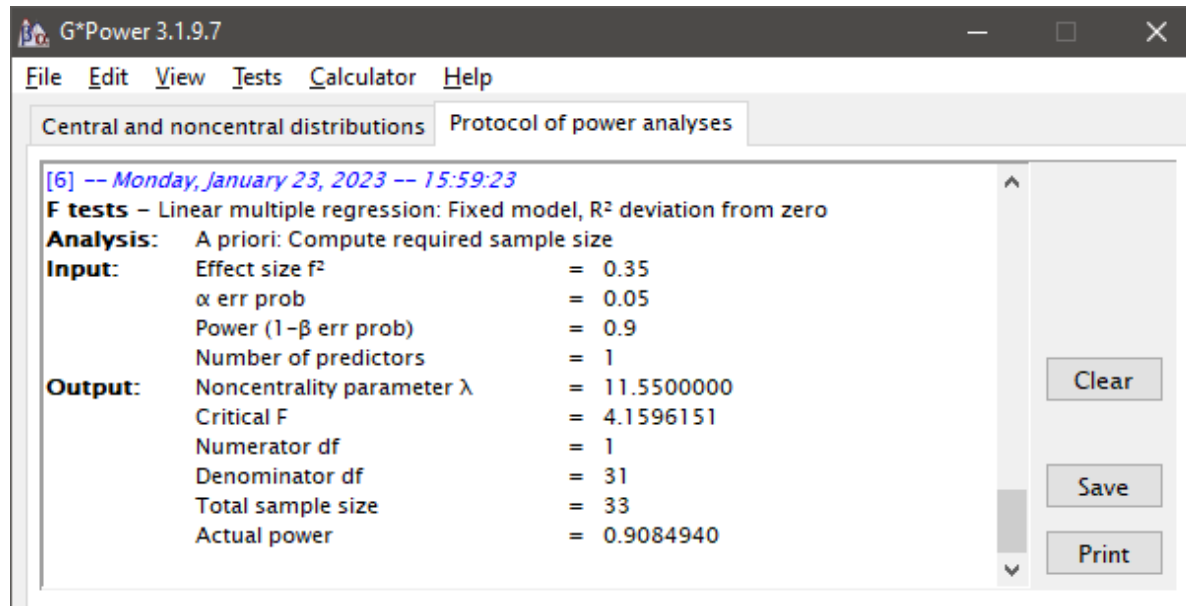
$f^2 = 0.35$

$\text{sig.level} = 0.05$

$\text{power} = 0.9$

Effektdefinition für verschiedene Tests

Einfache lineare Regression



Effektdefinition für verschiedene Tests

Multiple lineare Regression

- Effekt: f^2
- $f^2 = r = \sqrt{R^2}$ (hier sollte der angepasste (adjusted) Wert genutzt werden)

`pwr.f2.test(u = , v = , f2 = , sig.level = , power =)`

- **u** Freiheitsgrade Zähler
- **v** Freiheitsgrade Nenner
- **f2** Effektstärke
- **sig.level** α
- **power** $1 - \beta$

Effektdefinition für verschiedene Tests

Korrelation

- Effekt: r
- $r = \text{Korrelationskoeffizient}$

pwr.r.test(n = , r = , sig.level = , power =)

- **n** Anzahl der Beobachtungen
- **r** Effektstärke
- **sig.level** α
- **power** $1 - \beta$

Effektdefinition für verschiedene Tests

Nicht-parametrische Tests (Wilcoxon)

Effekt: Cohen's D

`pwr.t.test(n = , d = , sig.level= , power = , type = , alternative=)`

- **n** Stichprobengröße
- **d** Effektstärke
- **sig.level** Signifikanzniveau
- **power** Teststärke
- **type** „one.sample“, „two.sample“, „paired“
- **alternative** „less“, „two.sided“, „greater“

(Gleiche Berechnung wie parametrisch)

Effektdefinition für verschiedene Tests

Nicht-parametrische Tests (Kruskal-Wallis)

- Effekt: f

- $f = \sqrt{\frac{\eta^2}{1-\eta^2}}$ mit $\eta^2 = \frac{SS_{zwischen}}{SS_{Gesamt}}$

pwr.anova.test(k = , n = , f = , sig.level = , power =)

- **k** Anzahl der Gruppen
- **n** Stichprobengröße (pro Gruppe)
- **f** Effektgröße
- **sig.level** α
- **power** $1 - \beta$

(Gleiche Berechnung wie parametrisch)

Effektdefinition für verschiedene Tests

Mehrfaktorielle Varianzanalyse (ANOVA)

- Effekt: f

- $f = \sqrt{\frac{\eta^2}{1-\eta^2}}$ mit $\eta^2 = \frac{SS_{zwischen}}{SS_{Gesamt}}$

`wp.kanova(n = , ndf = , f = , ng = , alpha = , power =)`

- **n** Stichprobengröße
- **ndf** Zählerfreiheitsgrade
- **f** Effektgröße
- **ng** Anzahl der Gruppen
- **alpha** α
- **power** $1 - \beta$

Effektdefinition für verschiedene Tests

Mehrfaktorielle Varianzanalyse (ANOVA)

```
> wp.kanova(ndf =2, f=0.25, ng=12, alpha=0.05, power=0.8)
```

Multiple way ANOVA analysis

n	ndf	ddf	f	ng	alpha	power
157.3764	2	145.3764	0.25	12	0.05	0.8

NOTE: Sample size is the total sample size

Effektdefinition für verschiedene Tests

Mehrfaktorielle Varianzanalyse (ANOVA)

